



CORPORACIÓN UNIVERSITARIA DEL HUILA – CORHUILA

Seguimiento de curso Fundamentos de la Inteligencia artificial

Integrantes: Barrera Giraldo Harold Camilo

Facultad De Ingeniería, Corporación Universitaria del Huila-CORHUILA

Programación Móvil

Docente: Jesus Ariel Gonzalez Bonilla

09 de octubre del 2025

Ética de la IA

Acerca de este curso

Le damos la bienvenida al curso Ética de IA. En este curso, se familiarizará con los conceptos relacionados con la ética de IA. La ética de IA es un campo multidisciplinal que estudia cómo optimizar la repercusión positiva de la IA y reducir los resultados no deseados o adversos. La confianza en la IA se basa en cinco pilares éticos:

- Imparcialidad
- Solidez
- Explicabilidad
- Transparencia
- Privacidad

Objetivos del curso

Después de completar este curso, debería ser capaz de:

- Identificar los cinco pilares de la ética de la IA
- Describir la imparcialidad en IA
- Describir los atributos protegidos
- Identificar grupos privilegiados y grupos no privilegiados
- Explicar el sesgo de la IA
- Identificar la solidez
- Describir la solidez frente a adversarios en la IA
- Explicar cómo un adversario puede influir en un sistema de IA
- Identificar ataques de adversario
- Describir la explicabilidad
- Comparar interpretabilidad y explicabilidad
- Definir la transparencia

- Describir el gobierno
- Identificar las funciones empresariales y los aspectos de la transparencia en los que intervienen
- Identificar información personal
- Identificar información personal confidencial
- Reconocer la anonimización de modelos
- Describir la privacidad diferencial
- Explicar la minimización de datos



5.1 ¿Qué es la ética de la IA?

Introducción

Todos los días interactuamos con sistemas de IA, pero ¿hasta qué punto confiamos en ellos? Este módulo explica brevemente los cinco pilares de la ética de la IA y la importancia de cada uno de ellos para crear modelos y sistemas de IA en los que se pueda confiar.

Objetivos del curso

Después de completar este módulo, debería ser capaz de:

- Identificar los cinco pilares de la ética de la IA



La edad de la IA

Lo que te entendí de este tema es que la **Inteligencia Artificial (IA)** **está en todas partes**, mejorando significativamente nuestras vidas al optimizar la navegación, las búsquedas, los **diagnósticos médicos precisos** y la previsión meteorológica, y ayudando a la gente a tomar decisiones más informadas. Sin embargo, la IA también tiene un lado oscuro con el potencial de causar **daño** —no necesariamente físico, sino en forma de **desigualdad, discriminación o exclusión**— al influir en decisiones críticas sobre la vida de las personas, como la aprobación de **préstamos, admisiones universitarias o penas de prisión**. Este daño puede ser sutil y difícil de percibir, ya que a menudo la gente no sabe cuándo está interactuando con un sistema de IA ni cómo está influyendo en las decisiones tomadas sobre ellos.

¿Puede ser fiable la IA?

Lo que te entendí de este tema es que, dada la creciente integración de la **Inteligencia Artificial (IA)** en la vida cotidiana, es crucial que los usuarios puedan **confiar** en ella. Esta confianza se infunde a través de la **Ética de la IA**, un campo multidisciplinar enfocado en **maximizar el impacto positivo** de la IA y **minimizar los resultados adversos**.

Los cinco pilares fundamentales que contribuyen a la fiabilidad de la IA y que serán explicados en detalle por John Thomas (Vicepresidente de IBM) son:

1. **Imparcialidad**
2. **Solidez**


3. Explicabilidad



4. Transparencia

5. Privacidad

Cuestionario



5.2 ¿Qué es la imparcialidad?

Introducción

En IA, imparcialidad es el tratamiento equitativo de individuos o grupos de individuos. La imparcialidad se consigue cuando se mitigan los sesgos no deseados. En IA, el sesgo es un error sistemático que se ha diseñado, intencionadamente o no, de forma que pueda generar decisiones injustas. El sesgo se puede encontrar en el sistema de IA, en los datos

utilizados para entrenar y probar el sistema, o incluso en ambos. El sesgo puede surgir en un sistema de IA debido a expectativas culturales, limitaciones técnicas o contextos de implantación imprevistos.

Objetivos del curso

Después de completar este módulo, debería ser capaz de:

- Describir la imparcialidad en IA
- Describir los atributos protegidos
- Identificar grupos privilegiados y grupos no privilegiados
- Explicar el sesgo de la IA


En la siguiente historia, Jordan, Priscilla y Nischal, empleados de una gran entidad bancaria nacional, le hablarán de imparcialidad y parcialidad al descubrir un problema de imparcialidad en un sistema de IA.




Conocer al equipo

Lo que te entendí de este tema es que la **imparcialidad** en los sistemas de IA se refiere a la necesidad crítica de que estos sistemas operen **sin sesgo ni discriminación** contra ningún grupo. La historia del gran banco que utiliza IA para identificar candidatos a ascensos ejemplifica cómo el sesgo puede introducirse en un sistema, ya que el modelo favorece a una sola raza en las promociones, forzando a la entidad a revisar la programación para entender y corregir la causa subyacente. En esencia, la imparcialidad busca evitar que los datos de entrenamiento sesgados refuercen **estereotipos y prejuicios**, garantizando un trato equitativo en la toma de decisiones por parte de la IA.


El equipo



Jordan (ellos/ellas)
Responsable de datos (CDO)



Priscila (ella)
Directora de operaciones de personal
(PeopleOps)




Nischal (él)
Director de ciencia de datos

Identificar el problema

Lo que te entendí de este tema es que Jordan, el nuevo responsable de datos del banco, se enfrenta a un problema de **imparcialidad y sesgo** en un nuevo sistema de IA que se estaba probando para identificar candidatos de alto valor para **ascensos**.

- **El Sistema:** La IA fue implementada para ayudar al grupo de PeopleOps a seleccionar a los candidatos a ascenso para el año.
- **El Descubrimiento del Sesgo:** Priscilla, la Directora de operaciones de personal, revisó la lista de ascensos generada por la IA y notó que un **número desproporcionado de los candidatos ascendidos eran blancos**.
- **La Evidencia del Error:** Priscilla se sorprendió, ya que la IA había excluido a un empleado no blanco que ella había recomendado específicamente y que consideraba el perfil perfecto.

La situación requiere que Jordan y Priscilla inicien una **investigación** para entender **qué está causando este sesgo** en el sistema de IA y por qué está fallando en la selección de candidatos calificados de minorías.




Lo que te entendí de este tema es que, ante la preocupación de Priscilla sobre el sesgo racial en los ascensos generados por la IA, Jordan ha solicitado al equipo de **ciencia de datos** que **inicie una investigación**.

El primer paso de esta investigación es un **análisis rápido de los datos históricos de ascensos de 5 años** que fueron utilizados para entrenar el sistema de IA. El texto menciona que la siguiente información es una muestra de los datos que recogieron, lo cual es fundamental para determinar si el sesgo del modelo proviene de un **sesgo preexistente en los datos de entrenamiento**. (Dado que no se proporcionó la tabla de datos, el resumen se limita al plan de acción).

Atributos del empleado	Empleado 1	Empleado 2	Empleado...
ID de empleado	1	2	...
Departamento del empleado	Datos e IA	Datos e IA	...
Cualificación del empleado	Máster	Doctorado	...
Raza del empleado	Blanca	No blanca	...
Años de antigüedad	10	12	...
Valoración media			...
Decisión sobre ascenso	Sí	No	...

El equipo recopila sus hallazgos iniciales en un gráfico que muestra los datos de ascensos y la raza de los candidatos:




Al observar el gráfico, Jordan se da cuenta de que históricamente ha habido un número desproporcionadamente mayor de candidatos blancos que de no blancos en el grupo final de candidatos a ascensos. Se les ocurre que el sistema podría tener un problema de imparcialidad que diera lugar a prejuicios basados en la raza.




Jordan reúne al equipo para hablar sobre el primer problema que han detectado y planificar lo que tienen que hacer a continuación.

Como primer paso para abordar el dilema, Jordan pregunta al equipo si creen que mantener el sistema de IA tiene valor para la empresa.

Jordan pregunta: “¿Creéis que deberíamos seguir utilizando la IA para ayudar en el proceso de ascensos?”.





Tras pensárselo un momento, Priscilla asiente con la cabeza.

“Si se hace bien y de forma que los miembros del equipo de PeopleOps puedan confiar, nos ahorrará tiempo y podría ayudarnos a que nuestro proceso de ascensos sea más justo”, afirma Priscilla.

Jordan, Priscilla y Nischal coinciden en que el valor de la IA está ahí, si se aplica correctamente.

Explicar el problema

Introducción


Lo que te entendí de este tema es que, en respuesta al problema de sesgo de imparcialidad detectado por Priscilla, Jordan ha tomado una medida crucial: le ha pedido a **Nischal** que colabore con el equipo de **Ciencia de Datos**. El objetivo de esta colaboración es **preparar materiales educativos** que ayuden al equipo de PeopleOps (Operaciones de Personal) a comprender las posibles **causas del sesgo** en el sistema de IA que identificaba candidatos para ascensos.

Diapositiva 1



Al día siguiente, Nischal y el equipo de PeopleOps se reúnen en la sala de reuniones. Nischal inicia el debate con el término **sesgo**.

Jordan pregunta a Nischal: “¿Puedes explicar el significado de **sesgo** en el contexto de la imparcialidad?”.




Nischal explica lo siguiente: “El sesgo, en general, es un error sistemático, pero en el contexto de la imparcialidad, el problema gira en torno al sesgo no deseado. El sesgo no deseado da a algunos grupos o individuos una ventaja sistemática y a otros grupos o individuos una desventaja sistemática”.

Continúa diciendo: “Entiendo que he utilizado algunos términos nuevos. Voy a explicarlos uno por uno”.

Diapositiva 3

Nischal presenta una diapositiva con la definición del sesgo y frases destacadas.

El sesgo no deseado da a los grupos privilegiados una ventaja sistemática y a los grupos no privilegiados una desventaja sistemática.



Priscilla pregunta: “¿Por qué dividir a la población en grupos?”

1 2 3 4 5 6 7 8 9 10 ✓




Nischal explica: “La razón de utilizar grupos es sencilla: mitigar la disparidad de resultados entre los grupos. En otras palabras, para obtener un resultado equitativo entre los grupos”.

Nischal continúa: “Dividimos la población en grupos basándonos en uno o más atributos de los datos que podrían introducir disparidad o desigualdad en el resultado. El atributo que separa a la población en grupos se denomina atributo protegido. Algunos de los atributos protegidos que se suelen utilizar son raza, edad, sexo al nacer, identidad de género y origen étnico. Pero no hay un conjunto definido de atributos protegidos”.



“Tradicionalmente, si un grupo recibe un resultado más favorable o ventajoso que otro grupo, se puede introducir sesgo y generar un resultado injusto. El grupo que tradicionalmente recibe resultados más favorables se denomina grupo **privilegiado**. El grupo que tradicionalmente recibe menos o ningún resultado favorable se denomina grupo no privilegiado. El objetivo de la imparcialidad en la IA es minimizar el impacto de los sesgos no deseados en el sistema”, concluye Nischal.

Diapositiva 7



Nischal presenta el siguiente gráfico, que representa 5 años de datos de ascensos, divididos por razas, para explicar el problema de la imparcialidad.


Nischal señala el gráfico: “En nuestros datos, la **raza** es uno de los posibles atributos protegidos”.



Nischal continúa preguntando al equipo: “¿Veis al patrón?”


“Los candidatos blancos tienen un mayor porcentaje de ascensos que los no blancos. Hemos introducido estos datos de 5 años en nuestro sistema de IA, que solo ha seleccionado al 2 % de los candidatos no blancos para un ascenso en 2022. El sistema de IA ha hecho su selección basándose en el historial de ascensos de la empresa”.

1 2 3 4 5 6 7 8 9 10 ✓



El equipo ha podido al fin vincular el concepto con su aplicación de ascensos. Jordan se une a la conversación y dice: “Así que, en nuestra aplicación de ascensos,

- Los empleados blancos están en el grupo privilegiado.
- Los empleados no blancos están en el grupo no privilegiado.
- La raza, cuando se utiliza para dividir a la población en grupos, introduce disparidad, y es el atributo protegido”.



Nischal confirma la conclusión de Jordan y concluye el análisis inicial diciendo: “Hay muchas formas a través de las cuales el sesgo puede entrar en el sistema de IA. Tenemos que investigar más a fondo cómo entró el sesgo en el sistema de ascensos. El tipo de imparcialidad (grupal, individual o ambas) en el que centrarse depende del problema. Hay muchos factores que pueden influir en la selección de los atributos protegidos, como los principios de la organización, el enfoque de la aplicación y la normativa. El equipo debe tener en cuenta todos los factores y elegir cuidadosamente los atributos protegidos. El equipo de ciencia de datos debe diseñar una forma de **comprobar los sesgos a lo largo del ciclo de**

Para ayudar al equipo a entender cómo puede surgir el sesgo en un sistema de IA, Nischal plantea una serie de preguntas basadas en el conjunto de datos que se utilizó para entrenar el modelo de IA.

[COMENZAR DE NUEVO](#)




1 2 3 4 5 6 7 8 9 10 ☒

Cuestionario



5.3 ¿Qué es la solidez?



Introducción

La IA se utiliza cada vez más para ayudar a tomar decisiones cruciales, por lo que es vital que sea segura y sólida. Cuando la IA es sólida, puede manejar con mayor eficacia condiciones excepcionales, como anomalías en la entrada de datos o ataques maliciosos, sin causar daños involuntarios.

Objetivos del curso

Después de completar este módulo, debería ser capaz de:

- Describir la solidez frente a adversarios en la IA
- Explicar cómo un adversario puede influir en un sistema de IA


- Clasificar los ataques de adversario

En la siguiente historia, aprenderá sobre solidez de la mano de Charlie, Manuel y Prashant, que debaten cómo garantizar que su sistema de IA se cree para resistir ataques de adversario.


Conocer al equipo

Un ataque adversario es un intento deliberado y malicioso de engañar a un modelo de IA alterando sutilmente los datos de entrada de una manera que es casi imperceptible para un humano, pero que fuerza al modelo a realizar una clasificación incorrecta; por ejemplo, en un sistema de diagnóstico médico, un atacante podría añadir un "ruido" invisible a una radiografía sana para que el sistema diagnostique falsamente cáncer, o viceversa. La solidez o robustez frente a adversarios es la capacidad del modelo para resistir estos ataques y mantener su precisión. Es esencial proteger los sistemas de IA, especialmente en áreas críticas como la sanidad, mediante técnicas de defensa y entrenamiento adversario, para prevenir diagnósticos erróneos que podrían tener consecuencias graves en la vida real.


El equipo



Charlie (ella)
Directora de tecnología (CTO)



Manuel (ellos/ellas)
Responsable de privacidad (CPO)




Prashant (él)
Responsable de datos (CDO)

Identificar el problema

Se acerca la fecha de lanzamiento de una aplicación basada en IA para ayudar a detectar el cáncer de pulmón mediante radiografías de tórax. Charlie, la Directora de tecnología, está revisando el plan con su equipo.



CURSO




Manuel, Responsable de privacidad, llama a la puerta y la abre lentamente. Charlie les hace señas para que entren.

Manuel se disculpa por la interrupción y dice: “Acabo de enterarme de que AY-APP se enfrenta a una demanda porque su aplicación diagnosticó erróneamente enfermedades a muchos pacientes del Centro de Salud Ocular C.L.”. El artículo afirma que los diagnósticos incorrectos ocasionaron a las compañías de seguros elevados costes en pruebas de seguimiento. Además, el estrés que ocasionó la situación a los pacientes afectó a su capacidad para trabajar y cuidar de sus familias durante meses. Parece que un ataque de adversario a su modelo de IA ha sido la causa del elevado número de diagnósticos incorrectos”.

El comentario de Manuel cambia el rumbo de la reunión.

Inmediatamente, Charlie piensa en la posibilidad de ataques de adversario.




Charlie dice: "Sé que la noticia nos ha sacudido un poco a todos".

Luego Charlie pregunta: "¿Todo el mundo sabe lo que es un **ataque de adversario**? Vamos a asegurarnos de que todos estamos de acuerdo en cuanto al concepto, las terminologías y las formas en que se puede atacar el sistema".

Luego pide a Prashant, Responsable de datos y Científico de datos, que se lo explique.

Explicar el problema




Prashant dice: “Empecemos por explicar qué es un ataque de adversario. Los ataques de adversario se llevan a cabo intencionadamente en sistemas de IA para lograr un objetivo final malicioso aprovechando las vulnerabilidades del sistema de IA.”


“El objetivo de un ataque de adversario es influir negativamente sobre el rendimiento del sistema, explotar los datos utilizados y corromper la lógica del modelo. El que se aprovecha de las vulnerabilidades del sistema de IA para lograr su objetivo se llama **adversario**”.

CUR

“La siguiente imagen es un ejemplo de cómo un ataque de adversario puede afectar al rendimiento de nuestro sistema”.




Los **ataques adversarios** contra la IA se manifiestan como la adición de diminutas **perturbaciones** o **ruido** calculado a los datos de entrada de un modelo, como una imagen, siendo estas alteraciones prácticamente **imperceptibles para el ojo humano**. Este **ruido** es diseñado específicamente para explotar las vulnerabilidades de la red neuronal, forzando al modelo desplegado a generar una **predicción no deseada o incorrecta**; por ejemplo, el sistema de diagnóstico médico podría clasificar una imagen cancerosa como sana o viceversa, lo que subraya la necesidad crítica de mejorar la **solidez** de la IA en entornos sensibles.




“Este escenario es solo para una entrada de usuario.
¿Os imagináis que este escenario se repitiera para
todas las radiografías de entrada?”


Charlie entra en la conversación y dice: “Da miedo. No
me imagino nuestro sistema en manos de adversarios.

¿Puedes dar más detalles sobre los objetivos finales
del adversario, cómo las acciones del adversario
pueden afectar a nuestro sistema, y las formas en que
el adversario puede entrar en el sistema?”





“Claro”, dice Prashant. “Veamos algunos de los posibles objetivos del adversario y cómo conectan con nuestra aplicación de IA”.



Prashant señala: “Hay varias formas en que un adversario puede lograr los objetivos mencionados anteriormente, incluidas las siguientes:


- Acceder a los datos de entrenamiento y conocer la distribución de los datos
- Tener permiso para modificar los datos utilizados para el entrenamiento y probar el sistema de IA
- Acceder al código y a los parámetros del modelo
- Dañar los datos de los usuarios y enviar los datos modificados al sistema de IA desplegado”

Lo que te entendí de este tema es que la seguridad de los sistemas de IA depende de su **solidez**, ya que un **adversario** (atacante) tiene la libertad de utilizar una **combinación de diferentes tácticas de ataque** en lugar de solo una. Es crucial entender que estos ataques adversarios pueden ocurrir en cualquier momento, tanto **durante la fase de**

entrenamiento del modelo como **después de su despliegue**, subrayando la necesidad de proteger la IA en todo su ciclo de vida.


El problema del envenenamiento

Prashant hace una pausa y piensa en los posibles ataques que puede sufrir su sistema de IA.



“Aunque existen diferentes tipos de ataques de adversario, la posibilidad de modificar la entrada es la más probable. Por lo tanto, basándonos en la observación inicial, nuestro sistema de IA puede ser susceptible a dos tipos de ataques de adversario: **envenenamiento y evasión**”.

Los miembros del equipo se miran con aprensión. Uno de ellos pregunta: “¿Podrías decirnos algo más sobre el envenenamiento? ¿Cómo funciona el envenenamiento?”



“Buena pregunta”, dice Prashant. “Como podéis ver, el envenenamiento se puede producir con cualquiera de las siguientes acciones durante la fase de entrenamiento del modelo:

- Inyectar muestras maliciosas en los datos de entrenamiento
- Actualizar las características y las etiquetas de los datos de entrenamiento
- Modificar la arquitectura, los parámetros y la lógica del modelo de IA”

“El ataque de envenenamiento tiene varias consecuencias. Una es cuando el modelo de IA desplegado se vuelve sensible al patrón específico de los datos maliciosos”.

“He preparado un escenario para mostraros cómo el envenenamiento puede afectar a los resultados de un sistema de IA”.

Escenario: Envenenamiento

El escenario de Prashant está en la interacción de abajo. Utilice las flechas para moverse por los escenarios.

En este escenario, dos adversarios se coordinan para realizar este ataque.

COMENZAR >

Escena 1

Adversario 1


El adversario accede al almacenamiento de datos y añade imágenes maliciosas con más luminosidad a los datos de entrenamiento para que el sistema pueda aprender el patrón.

Luego, el adversario proporciona detalles sobre el aumento porcentual de la luminosidad a otro adversario, posiblemente alguien que trabaje en el hospital.

Adversario 2


Cuando se utiliza el modelo de IA, otro adversario, que trabaja en el hospital, puede modificar fácilmente la entrada enviada al modelo de IA basándose en la información recopilada sobre el aumento del rango de luminosidad y obtiene el resultado deseado.

Fase de entrenamiento: Datos enviados al modelo para el entrenamiento




Durante la fase de entrenamiento, el Adversario 1 inserta los datos que contienen muestras maliciosas (elementos sombreados) dando lugar a un modelo de IA que está mal entrenado. Las muestras maliciosas están etiquetadas como **Enfermedad**, pero en realidad no muestran enfermedad. Cuando se añaden al resto de los datos de entrenamiento, se obtiene un modelo de IA que no genera resultados precisos.

Después del despliegue: Las entradas se envían al modelo desplegado para que haga predicciones



Una vez desplegado el modelo, el Adversario 2 ajusta la entrada al modelo de IA desplegado basándose en las características de la muestra maliciosa. Por ejemplo, el Adversario 2 manipularía la entrada de manera que una entrada que no muestre enfermedad sea etiquetada por la IA como Enfermedad. Esto podría dar lugar a que el sistema de IA identificara a personas sin enfermedad como personas que podrían tenerla.

1 2 (3) ✓




Prashant añade: "¿Os habéis dado cuenta de que el sistema es sensible a las entradas corruptas? Ahora, veamos el ataque de evasión".

El problema de la evasión


La evasión puede ocurrir después de la fase de despliegue del modelo con cualquiera de las siguientes acciones:

- Enviar muestras de pruebas maliciosas al modelo desplegado
- Corromper los datos de prueba que se envían al modelo desplegado



Prashant dice: “El ataque de evasión tiene varias consecuencias. Una es cuando un adversario encuentra los cambios en la entrada necesarios para hacer que el sistema produzca una predicción incorrecta. Dejad que os muestre el concepto con otro escenario y visual”.

Escenario: Evasión



6.

TERMINA
CURSO

Observa la respuesta
del sistema



7.



Identifica el rango de luminosidad
necesario para que sistema genere una
clasificación incorrecta



Lo que te entendí de este tema es que Prashant concluyó su presentación enfatizando la necesidad de hacer que su sistema de IA sea **sólido** (o robusto) para protegerlo eficazmente contra posibles **ataques de adversario**.

El equipo, incluyendo a Charlie, se sintió **aliviado** al saber que la organización tiene un buen entendimiento sobre cómo funcionan estos ataques y que están en el camino correcto para implementar las soluciones necesarias que eviten futuras interferencias maliciosas. Esto demuestra la importancia del pilar de la **solidez** en la ética de la IA.

Cuestionario



¿Qué es la explicabilidad?

Lección 17 de 37

Acerca de este módulo

Módulo 4
¿Qué es la explicabilidad?

IBM SkillsBuild

TERMINAR CURSO

Introducción

Un sistema de IA es **explicable** cuando la gente corriente, que no tiene una formación especial en IA, puede entender cómo y por qué el sistema ha llegado a una predicción o recomendación concreta. La explicabilidad es como mostrar su trabajo en un problema de matemáticas para que todo el mundo pueda ver los pasos que ha dado para llegar a la respuesta.

Objetivos del curso

Después de completar este módulo, debería ser capaz de:

- Describir la explicabilidad
- Describir la interpretabilidad
- Comparar interpretabilidad y explicabilidad

En la siguiente historia, aprenderá sobre explicabilidad con Olivia, Clara y Luan mientras responden a las opiniones de los clientes sobre las recomendaciones de productos generadas por su sistema de IA.

Conocer al equipo

Lo que te entendí de este tema es que, tras implementar un sistema de **recomendación de productos basado en IA**, la empresa de comercio en línea descubrió una necesidad de **Explicabilidad** por parte de los clientes, quienes desean entender el **porqué y el cómo** se les hacen las sugerencias de productos.

Por lo tanto, el equipo de ciencia de datos está trabajando en:

1. **Investigar diferentes métodos** para explicar los modelos de IA de maneras que sean **relevantes para los distintos tipos de usuarios** (no todos necesitan el mismo nivel de detalle técnico).
2. **Generar una serie de preguntas** fundamentales para guiar la reflexión y la resolución de este tipo de problemas de explicabilidad.


El equipo



Olivia (ella)
Jefa de dirección de IA



Clara (ellos/ellas)
Experto en datos




Luan (ella)
Científica de datos y validadora de modelos

Identificar el problema

Lo que te entendí de este tema es que una **empresa de comercio en línea** ha implementado un nuevo **sistema de recomendación de productos basado en IA** con el objetivo de optimizar la experiencia de compra.

Tras el lanzamiento de esta nueva función, el equipo de **Ciencia de Datos** está ahora enfocado en la siguiente fase crítica: **recopilar y analizar los comentarios** de los clientes. Este análisis de *feedback* es esencial para evaluar el rendimiento del sistema, identificar áreas de mejora y, como se vio en el tema anterior, probablemente determinar si los clientes entienden y confían en las razones detrás de las recomendaciones (el pilar de la **Explicabilidad**).



Estas son algunas de las preguntas de los clientes sobre las recomendaciones:


“¿Por qué me recomiendan este producto? Aunque me gusta el diseño, ¿cómo puedo fiarme de las recomendaciones?”

“No había visto antes esta función. ¿Es una recomendación basada en IA?”

“Me he fijado en esta fantástica función de recomendación, pero me gustaría saber qué hay dentro del proceso de recomendación.”

“¿Hay alguna manera de desactivar las recomendaciones? No quiero dejarme influenciar por ellas porque no estoy seguro de lo que contienen estas recomendaciones.”

El equipo de Ciencia de datos crea un informe con los comentarios recibidos y lo envía por correo electrónico a Olivia.



Casualmente, Olivia está leyendo un artículo sobre la importancia de crear sistemas de IA fiables para que las empresas puedan seguir siendo competitivas en el mercado, ganarse la confianza de los clientes y crear confianza en la IA fiable.

Olivia recibe el correo electrónico del equipo y queda gratamente sorprendida por la puntualidad del informe. Se pregunta si el equipo de Ciencia de datos debería dedicar tiempo a añadir una nueva función para explicar de dónde vienen las recomendaciones.

Lo que te entendí de este tema es que, tras recopilar los datos y analizar el *feedback* de los clientes, **Olivia** convocó una sesión de *brainstorming* con su equipo para abordar el tema de la **confianza del cliente** en el sistema de recomendación de productos.


Al inicio de la reunión, Olivia agradeció el trabajo del equipo de ciencia de datos y subrayó la **importancia crítica** de crear **sistemas de IA fiables**, resumiendo su postura con la frase: "**Una IA fiable no es un extra, sino un requisito esencial**". Esta frase establece el tono de la sesión, indicando que la fiabilidad debe ser una característica central y no un añadido opcional en su sistema de comercio en línea.



El equipo empieza a comprender que la fiabilidad de la IA puede ser más importante de lo que pensaban en un principio.


Explicar el problema

Clara pregunta: "Entonces, ¿deberíamos centrarnos en hacer que nuestro modelo sea interpretable?".




TERMINAR
CURSO

Luan pregunta: "¿Deberíamos centrarnos en la explicabilidad de la decisión del modelo?".



Olivia cree que estas preguntas son una buena manera de guiar al equipo en la dirección correcta.




“¡Excelentes preguntas!” exclama Oliva. “Pero primero tenemos que entender lo que significa cada término. Tanto la **explicabilidad** como la **interpretabilidad** son formas de entender cómo funciona el modelo”.

“La **interpretabilidad** es el grado en que un observador puede entender la causa de una decisión. Es el porcentaje de éxito con el que los humanos pueden predecir el resultado de una salida de IA, mientras que la **explicabilidad** va un paso más allá y examina cómo el sistema de IA ha llegado a un resultado”.

“Ahora vamos a ver un escenario que conectará esos términos con nuestro sistema para que podamos entenderlos mejor”.

Escenario: Recomendaciones para comercios



Olivia dice al equipo: “Aquí tenemos un escenario que conectará los términos con nuestra aplicación para que podamos entenderlos mejor”.


Escena 1

Imagine que un cliente busca “proteína en polvo”. El sistema de inteligencia artificial le recomienda tres proteínas en polvo basándose en las anteriores pautas de compra del cliente. La información utilizada como entrada para el sistema de recomendación es:

- Indicador sin azúcar (Sí/No)
- Sabor (chocolate, vainilla y sin sabor)

1 2 3 4 5 6 7 8 ✓


Escena 2



Aquí hay dos modelos recomendación, el Modelo A y el Modelo B. Cada modelo proporciona tres recomendaciones de productos (P2, P4 y P5).

El Modelo A utiliza un simple árbol de decisión para generar los productos que recomendar. El Modelo B usa una red neuronal para generar tres recomendaciones, pero no hay forma de saber qué llevó al modelo a generar las recomendaciones.


1 2 3 4 5 6 7 8 ✓



Olivia dice: “Clara, si te pido que me expliques el porqué de las recomendaciones, ¿qué flujo del modelo te resultaría más fácil de entender y explicar?”.

1 2 3 4 5 6 7 8 ✓


Escena 4




“Desde luego, el Modelo A”, responde Clara. “Puedo seguir fácilmente el flujo y entender la razón de una decisión. El Modelo B se parece más a un laberinto. Es difícil seguir lo que está pasando”.

1 2 3 4 5 6 7 8 ✓

Escena 5




“¡Perfecto!” Dice Olivia. “El Modelo A se puede interpretar porque se puede rastrear y comprender fácilmente el motivo de la recomendación. Sin embargo, se necesitan métodos explicables o nuevas técnicas para rastrear y comprender el razonamiento que subyace a las recomendaciones del Modelo B”.



“Estoy de acuerdo con Olivia”, dice Luan, “pero yo hago tanto de validador de modelos como de científico de datos. No creo que podamos utilizar las mismas explicaciones para todos los usuarios del modelo de IA. Supongo que las explicaciones deben cambiar según los usuarios”.


1 2 3 4 5 6 7 8 ✓

▶ Energía y ba



“Eso es cierto, Luan. ¿Puedes explicar al equipo a qué te refieres?”. pregunta Oliva.

1 2 3 4 5 6 7 8 ✓



“Bueno, solo estoy pensando en voz alta”, dice Luan, “pero entre las posibles personas que pueden necesitar y utilizar explicaciones de modelos están las siguientes:

- Usuarios de las recomendaciones del sitio web
- Encargados de aprobar los modelos (interno)
- Auditores de modelos (externo)
- Científicos de datos y validadores de modelos”

Explicaciones del modelo

Con esto concluye el escenario.




[COMENZAR DE NUEVO](#)



1 2 3 4 5 6 7 8 

Explicaciones del modelo

Veamos ahora cómo cambian las explicaciones sobre las recomendaciones para cada persona que ha mencionado Luan.



Productos recomendados

Abrazar el descubrimiento

Es posible que los usuarios quieran entender cómo el sistema de IA les hace recomendaciones específicas. También les gustaría saber qué medidas pueden tomar para recibir recomendaciones parecidas o distintas en el futuro.

Se recomendó *P2*, ya que anteriormente había comprado productos sin azúcar o con sabor a vainilla.

Se recomendaron *P4* y *P5* en base a su búsqueda de productos con sabor a vainilla o productos que no contengan azúcar.

Aprobadores y auditores

Es posible que los aprobadores y los auditores deseen comprender los pasos generales de la toma de decisiones sobre el modelo en función de las características. Tanto los aprobadores como los auditores pueden acabar cotejándolo con las explicaciones de usuarios aleatorios. El objetivo puede ser evaluar el modelo con respecto a los requisitos normativos o las políticas internas.

El producto se recomendará en función del indicador sin azúcar y las características de sabor.

No se usa información de identificación personal para construir el sistema de recomendación de IA.

Los usuarios con un comportamiento de compra similar reciben recomendaciones de productos similares.

Científicos de datos y validadores de modelos

Es posible que los científicos de datos y los validadores de modelos deseen conocer el rendimiento general del modelo, el efecto de las características en el rendimiento y otros tipos de explicaciones para evaluar el modelo.

Características del modelo:


- Indicador sin azúcar
- Sabor

¿Cómo se verá afectado el sistema de recomendaciones si se elimina la característica Sabor?

Lo que te entendí de este tema es que Olivia y Clara, junto con su equipo, reconocieron la utilidad de la **correlación** para avanzar en la **explicabilidad del modelo de IA**.

Agradecieron a Luan por su explicación y, en conjunto, dieron por concluida la sesión de *brainstorming*. El siguiente paso planificado es una reunión para diseñar el **plan de desarrollo e implementación** para lograr un sistema de IA más transparente y confiable.

Cuestionario



5.5 ¿Qué es la transparencia?

Acerca de este módulo

Introducción

Cuando un sistema de IA es **transparente**, se comparte información sobre qué datos recopila, cómo usa y almacena los datos y quién tiene acceso a los datos. Cuando se implementa de manera efectiva, la transparencia en la IA es como levantar el capó de un automóvil para que todos vean cómo funcionan juntas las diferentes partes del motor.

Objetivos del curso

Después de completar este módulo, debería ser capaz de:


- Definir la transparencia
- Describir el gobierno
- Identificar las funciones empresariales y los aspectos de la transparencia en los que intervienen

En la siguiente historia, aprenderá sobre la transparencia con Patricia, Abi, Stacey y Daniel mientras trabajan para hacer que su sistema de IA sea más transparente para sus usuarios.

Conocer al equipo

Lo que te entendí de este tema es que uno de los bancos más grandes del mundo estaba probando un sistema de **IA para automatizar la aprobación de hipotecas**, y aunque el propietario, Abi, estaba impresionado, su solicitud de ver los **detalles clave** del sistema reveló una severa **falta de Transparencia**, ya que la información no estaba claramente documentada ni era fácil de entender. Para abordar este pilar ético de la IA y generar


confianza, el equipo se dedicó a crear un **estándar de documentación** exhaustivo que abarcara todos los aspectos del sistema, desde sus **fuentes de datos** hasta la lógica de sus **predicciones y recomendaciones**, garantizando así que los procesos del sistema fueran abiertos y comprensibles.



Patricia (ella)
Responsable de datos (CDO)



Abi (él)
Propietario
de la empresa



Stacey (ella)
Jefa de IA



Stacey (ella)
Jefa de IA

Identificar el problema

Lo que te entendí de este tema es que la entidad bancaria está inmersa en una **transformación digital** impulsada por la IA y los datos, habiendo realizado **inversiones significativas en expertos en IA**.

El equipo de IA, con gran entusiasmo, ha desarrollado una **prueba de concepto** en tan solo un mes con el objetivo de **automatizar el proceso de aprobación de hipotecas** mediante IA. La Jefa de IA, **Stacey**, se encargará ahora de presentar esta prueba de concepto al propietario de la empresa, **Abi**.




Lo que te entendí de este tema es que Stacey concluyó la presentación del sistema de IA de aprobación de hipotecas asegurándole a Abi que el equipo se enfocó en la **fiabilidad** del sistema.

Para lograrlo, Stacey mencionó que el equipo abordó **cuatro de los cinco pilares éticos de la IA** con acciones concretas:

1. **Imparcialidad:** Han **evaluado la imparcialidad** del modelo para asegurar que no contenga sesgos.
2. **Explicabilidad:** Han **añadido funciones de explicabilidad** para que las predicciones sean comprensibles.
3. **Solidez:** Han **probado la solidez** del sistema para resistir ataques adversarios.
4. **Privacidad:** Han **documentado todas las medidas de privacidad** de los datos.

Stacey ahora espera la aprobación de Abi para el sistema, el cual ha sido desarrollado bajo un fuerte marco ético de IA.



Abi comienza diciendo: “Quiero agradecerte a ti y al equipo por el arduo trabajo en el desarrollo de esta prueba de concepto. Estoy muy emocionado y ansioso por el nuevo trayecto de IA de nuestra empresa.”


“Sin embargo, tengo curiosidad por saber más sobre la fuente de datos, cómo transformamos los datos, cómo se ha gestionado toda la información de identificación personal, el rendimiento del modelo y otros resultados de la evaluación. ¿Me podéis proporcionar más detalles sobre todo el proceso y sobre las decisiones tomadas?”

Stacey envía un mensaje a Daniel y le pide los detalles solicitados.

Daniel se sienta frente a su ordenador y comienza a mirar los archivos. Mientras examinar los detalles, se da cuenta de que cada miembro del equipo tiene su propia forma de registrar su proceso y sus hallazgos. Los detalles no se han registrado de la misma manera. Daniel reenvía el enlace a la documentación con reservas, porque sabe que la información no es fácil de entender.



Cuando Stacey y Abi comienzan a revisar los detalles, se dan cuenta de la necesidad de estandarizar el proceso de documentación.




Abi concluye: “Lo podemos solucionar. Conectémonos con Patricia para analizar cómo podemos aumentar la transparencia en el proceso y crear una forma estándar de documentar los detalles para mejorar el gobierno de los datos”.

Explicar el problema

Patricia, Stacey y Abi se reúnen en una sala de reuniones. Patricia monta una sesión de pizarra electrónica.

Patricia empieza escribiendo los objetivos principales de transparencia y gobierno de datos.



La transparencia consiste en revelar la información relacionada con los datos utilizados para crear sistemas de IA, tomar decisiones de diseño a lo largo del proceso, crear modelos, evaluar los modelos e implementar los modelos.


La gobernanza garantiza que el proceso seguido durante la creación y la implementación siga las políticas internas para crear una IA fiable.

Si aumentamos la transparencia, podemos mejorar la gobernanza.

Lo que te entendí de este tema es que Patricia recordó al equipo que, para generar **confianza** en los sistemas de IA de la organización, es fundamental que el proceso de desarrollo cubra cinco áreas clave de enfoque, que constituyen los pilares de la ética de la IA:


1. **Imparcialidad**

2. **Solidez**
3. **Explicabilidad**
4. **Transparencia**
5. **Privacidad**



Patricia comienza: “Vamos a probar un sencillo ejercicio. Vamos a crear un marco simple que nos ayude a entender qué detalles principales sobre el sistema están disponibles y quién puede proporcionarlos”.

Stacey y Abi están entusiasmados con el ejercicio y están listos para comenzar de inmediato.




“Muy bien”, dice Patricia, “empecemos. Stacey, ¿me puedes proporcionar una lista de los roles que participaron en la creación de nuestro sistema de IA? Abi, ¿me puedes proporcionar una lista de los datos que debe reunir el equipo?”

Lo que te entendí de este tema es que, tras la presentación de Stacey, Abi y ella comenzaron a documentar la información del nuevo sistema de IA de aprobación de hipotecas. Intervino **Patricia**, quien dividió una pizarra en **dos secciones** y les pidió que añadieran los detalles recopilados. Este ejercicio tiene como objetivo crear una **visión holística** del sistema, asegurando que se contemplen todos los aspectos clave de los pilares éticos y de la operación para generar confianza.


(Se aclara que, aunque el proceso en la historia es rápido, en la vida real requeriría una deliberación mucho más extensa).




El equipo mira la pizarra y se siente motivado al ver que las cosas finalmente cuadran.




“Es genial”, dice Patricia entusiasmada. “Ahora, vamos a correlacionar los roles con los datos. Con esta correlación, podemos aclarar las responsabilidades de las personas que participan en el proceso”.








FINALIDAD	DISEÑO	DATOS	MODELO	DE
-----------	--------	-------	--------	----




D	DISEÑO	DATOS	MODELO	DESPLIEGUE
---	--------	-------	--------	------------



Lo que te entendí de este tema es que Patricia y el equipo lograron **correlacionar los datos con los roles** y crearon una **plantilla estandarizada** para registrar la información en cada fase del proyecto de IA de aprobación de hipotecas.

Como siguiente paso, el equipo decidió **probar el flujo general** de trabajo para identificar y realizar mejoras necesarias. Stacey y Abi se mostraron satisfechos y aliviados de haber detectado la necesidad de esta **estandarización** en la documentación a tiempo. Con un **plan claro** para mejorar la documentación, la reunión concluyó con el objetivo cumplido de aumentar la **transparencia** del sistema.

Cuestionario



5.6 ¿Qué es la privacidad?



Introducción

Los datos son el centro de la IA. Puesto que la IA ingiere tantos datos para aprender, identificar patrones y hacer predicciones o recomendaciones, debe priorizar y salvaguardar **la privacidad** de todos los datos con los que entra en contacto.

Objetivos del curso

Después de completar este módulo, debería ser capaz de:


- Identificar información personal
- Identificar información personal confidencial
- Reconocer la anonimización de modelos Describir la privacidad diferencial

- Explicar la minimización de datos

En la siguiente historia, aprenderá sobre la privacidad con Kamal, Nia y Adrian, quienes aprenden a proteger la privacidad mientras desarrollan un sistema de IA.

Conocer al equipo


Lo que te entendí de este tema es que la **privacidad** es un pilar ético central de la IA, cuya importancia se evidenció cuando una gran **institución educativa** buscó ofrecer cursos en línea y desarrolló un **modelo de IA para recomendar planes de estudio personalizados**. Durante este proceso, el equipo se enfrentó a serios problemas relacionados tanto con la **privacidad de los datos** (la información sensible del estudiante usada para el entrenamiento) como con la **privacidad de la IA** (el riesgo de que el modelo pudiera revelar o inferir información sensible sobre los individuos), obligando al equipo a investigar y aplicar medidas rigurosas para **proteger la privacidad** y garantizar el uso ético del sistema.



Kamal (él)
Responsable de datos (CDO)



Nia (ella)
Equipo de privacidad de datos



Adrian (él)
Equipo de desarrollo de IA

Explicar el problema

Lo que te entendí de este tema es que una **institución educativa** busca expandir su alcance creando un **campus global en línea**, con el objetivo estratégico de ofrecer **experiencias de aprendizaje personalizadas** a sus estudiantes.

Para lograr esto, el equipo de desarrollo empresarial decidió que el método más eficaz es utilizar un **modelo de IA** para crear **planes de estudio personalizados**. Por ello, contactaron al equipo de ciencia de datos, que ha desarrollado un **modelo de IA de prueba de concepto** utilizando datos de muestra extraídos del portal de aprendizaje de la institución. Ahora, ambos equipos se reúnen para **revisar y evaluar** este modelo inicial.



Lo que te entendí de este tema es que, durante la revisión del modelo de IA de planes de estudio, la presentación se interrumpió debido a una preocupación crítica relacionada con el pilar de la **Privacidad**.

El interlocutor (probablemente un miembro del equipo de desarrollo comercial) expresó su **preocupación y sorpresa** al no haber sido informado de que los datos sensibles del **portal de aprendizaje** se utilizaron para crear el modelo de IA, ya que asumían que esos datos eran **privados**. El requisito ahora es que **Kamal** debe asegurar que la **privacidad de los usuarios sea respetada**. Kamal, al no tener una respuesta inmediata, solicitó consultar a su equipo de ciencia de datos antes de proporcionar una explicación sobre la **protección de la privacidad** del modelo.



Identificar el problema

Lo que te entendí de este tema es que, tras la preocupación expresada sobre la **privacidad** del modelo de IA, **Kamal** se reunió con su equipo y se dio cuenta de que

carecía de información suficiente sobre los conceptos básicos de privacidad para implementar las protecciones adecuadas.

Para resolver esto, solicitó la ayuda de dos expertos: **Nia**, del **Equipo de Privacidad de Datos**, y **Adrian**, del **Equipo de Desarrollo de IA**. Ellos serán los encargados de aclarar los términos y conceptos fundamentales de privacidad necesarios para que el equipo pueda determinar las salvaguardas que deben ser implementadas en el sistema de planes de estudio personalizados.

El problema de la privacidad de los datos



IER
CI



Nia explica: "Las personas pueden proteger la información o los datos relacionados con ellas. Además, en algunos países, las personas tienen derecho a la privacidad de los datos; aunque es importante recordar que la definición de privacidad y los tipos de datos que se aplican varían de un país a otro. [En este mapa](#) se muestra cómo varía la normativa sobre privacidad en el mundo."


Lo que te entendí de este tema es que, para proteger la **privacidad** en los sistemas de IA, es fundamental distinguir entre dos categorías de datos: la **Información Personal (PI)**, que son datos que identifican a un individuo (como un nombre o código postal), y la **Información Personal Confidencial (SPI)**, que es información cuya exposición podría causar un daño grave o indebido a la persona (como un número de cuenta bancaria o una fecha de nacimiento). Al desarrollar modelos de IA que utilicen datos de estudiantes, como en el caso de la institución educativa, es crucial identificar y aplicar las máximas protecciones a la **SPI** para asegurar que la privacidad del usuario sea respetada en todo momento.

Kamal pregunta: "Gracias, Nia. Pero, ¿qué tiene esto que ver con la IA?"




Adrian, del Equipo de desarrollo de IA dice: "Buena pregunta, Kamal. Como los modelos de aprendizaje automático que impulsan la IA a menudo necesitan ser entrenados utilizando información personal o confidencial, es fundamental que los sistemas de IA prioricen y protejan la privacidad. Si se entrena a un modelo con información personal o confidencial sin aplicar ningún control de privacidad, entonces podría ser vulnerable a infracciones o ataques".

Kamal pregunta: “¿Infracciones y ataques? ¿Puedes darnos un ejemplo?”




CUR



Adrian explica: “Pongamos un ejemplo de un tipo de ataque a la privacidad: **el ataque por inferencia de pertenencia**. En un ataque de inferencia de pertenencia, un atacante intenta determinar si un individuo específico formaba parte del conjunto de datos de entrenamiento.


Puesto que los datos de las personas incluidas en el conjunto de datos de entrenamiento se ven comprometidos, se viola su privacidad. Por lo tanto, cuando desarrollamos un sistema de IA o entrenamos un nuevo modelo, nuestro objetivo debe ser preservar y proteger la privacidad de las personas en la medida de lo posible”.

Kamal pregunta: “¿Y qué podemos hacer para proteger la privacidad?”




El problema de la privacidad de los datos

c



Adrian responde: “Hay varios controles de privacidad que se pueden aplicar para reforzar la IA contra posibles vulneraciones de datos confidenciales. Dos que se implantan durante el entrenamiento del modelo son **la anonimización del modelo y la privacidad diferencial**. Uno que se implanta después del entrenamiento del modelo es la minimización de datos. Vamos a examinar cada uno de ellos”.



Adrian concluye: “Al aplicar controles de privacidad como la anonimización del modelo y la privacidad diferencial durante el entrenamiento del modelo, y la minimización de datos después del entrenamiento del modelo, podemos reforzar nuestros modelos contra las vulneraciones de datos personales y proteger la privacidad de las personas”.

Kamal agradece a Nia y Adrian por su ayuda y programa otra reunión con el equipo de dirección para hablar sobre los controles de privacidad que implementarán en el sistema de IA.

Cuestionario



Cuestionario Final

Ética de la IA

98% COMPLETA

Explicar el problema

Identificar el problema

Abordar el problema

Cuestionario

RESUMEN Y EVALUACIÓN FINAL

¡Ha llegado muy lejos!

Principales puntos que recordar

Explorar más

Evaluación final

Finalización del curso

Resultados del cuestionario

Tu calificación 87%

APROBADO 80%

INTENTAR DE NUEVO

TERMINAR CURSO

Ética de la IA

98% COMPLETA

Explicar el problema

Identificar el problema

Abordar el problema

Cuestionario

RESUMEN Y EVALUACIÓN FINAL

¡Ha llegado muy lejos!

Principales puntos que recordar

Explorar más

Evaluación final

Finalización del curso

Enhorabuena

Ya casi ha terminado.

¡Gane una credencial!

Recordatorio: Este curso es uno de los varios de la serie Fundamentos de la Inteligencia Artificial.

Complete todos los cursos del plan de aprendizaje sobre **Fundamentos de la Inteligencia Artificial** y obtenga la credencial digital de Fundamentos de la Inteligencia Artificial de IBM.

Artificial Intelligence Fundamentals

IBM SkillsBuild



TERMINAR CURSO

ole03.yourlearning.ibm.com/scom_package_symbol/scom_packages/_/index.html